

基于 LSTM 负荷预测与 SineKAN-DQN 动态权重调节的燃料电池/锂电池混合动力船舶能量管理

摘要

针对燃料电池/锂电池混合动力船舶在复杂航行工况下负荷波动强、燃料电池动态响应与寿命约束明显、锂电池 SOC 安全与氢耗经济性难以同时兼顾等问题，本文提出一种基于 LSTM 负荷预测与 SineKAN-DQN 动态权重调节的 MPC 能量管理框架。研究对象为“三峡氢舟 1 号”燃料电池/锂电池混合动力船舶。根据系统规格，该船燃料电池总功率为 560 kW，锂电池总储能为 1806 kWh，额定推进功率为 2×500 kW，日用负荷等级为 100 kVA。为避免仅采用左右推进逆变器有功功率造成负荷口径偏窄，本文采用燃料电池总发电功率与锂电池带符号净功率之和构造能源侧等效总负荷，并基于 66 个实船航段按起始时间顺序进行 7:2:1 的训练、验证和测试划分，以模拟利用前期航段训练并对后期未来航段泛化的真实部署场景。

方法上，首先建立燃料电池氢耗、锂电池 SOC、直流母线功率平衡、功率约束和能量吞吐模型；其次利用 LSTM 对下一控制时域内未来 6 个采样点负荷进行短时多步预测；再次构建以氢耗、SOC 偏差、电池吞吐和燃料电池功率变化为主要目标的 MPC 滚动优化控制器，并采用“下一控制时域”控制时序，使 MPC 在 t 时刻基于 LSTM 预测的 $t+1$ 至 $t+6$ 负荷求解未来燃料电池功率序列，实际执行时由锂电池补偿当前负荷与燃料电池执行功率之间的差额。进一步地，本文设计 SineKAN-DQN 高层调权器，将强化学习动作定义为 MPC 目标函数权重重组，而不是直接输出燃料电池或锂电池功率指令，从而在保留 MPC 物理约束与可解释性的同时增强多工况自适应能力。当前论文为理论、方法和实验设计完整初稿，流程图与最终实验结果图仍保留占位，后续需由代码输出和实测仿真结果补充，不对尚未完成的实验结果作数值性结论。

关键词：燃料电池船舶；锂电池；LSTM；模型预测控制；DQN；SineKAN；动态权重调节；能量管理

Abstract

To address the energy management problem of fuel-cell/battery hybrid ships under highly variable operating conditions, this paper develops a hierarchical framework integrating LSTM-based load forecasting, model predictive control, and SineKAN-DQN-based dynamic weight adaptation. The investigated platform is the Three Gorges Hydrogen Boat No. 1. An energy-side equivalent total load is defined by combining the total fuel-cell generation power and the signed net battery power, rather than using propulsion inverter power alone. An LSTM model provides short-term multi-step forecasts for the next control horizon, while an MPC controller optimizes fuel-cell power in a receding-horizon manner. A SineKAN-DQN agent is further designed to select MPC objective weights instead of directly issuing power commands, thereby preserving the constraint-handling and interpretability of MPC while improving adaptability to different load, SOC, and forecast-uncertainty

conditions. This manuscript does not fabricate experimental results; figures, tables, and numerical comparisons are left as placeholders to be filled by subsequent verified simulations and training outputs.

Key words: fuel-cell ship; lithium battery; LSTM; model predictive control; DQN; SineKAN; adaptive weighting; energy management

目录

摘要.....	1
Abstract.....	1
目 录.....	3
1 引言.....	5
1.1 研究背景.....	5
1.2 研究问题.....	5
1.3 国内外研究现状.....	5
1.3.1 混合动力船舶能量管理研究.....	5
1.3.2 负荷预测与预测型能量管理.....	6
1.3.3 DQN、KAN 与 SineKAN 研究进展.....	7
1.4 本文研究内容与章节安排.....	7
2 混合动力船舶数学建模.....	8
2.1 研究对象与动力系统组成.....	8
2.2 能源侧等效总负荷建模.....	8
2.3 航段数据集与预处理模型.....	9
2.4 直流母线功率平衡模型.....	9
2.5 燃料电池功率、效率与氢耗模型.....	9
2.6 锂电池 SOC 与吞吐模型.....	10
2.7 建模假设与参数标定需求.....	11
3 算法与能量管理建模.....	11
3.1 总体框架.....	11
3.2 LSTM 负荷预测模型.....	11
3.3 MPC 滚动优化与能量管理模型.....	12
3.4 DQN 动态权重调节模型.....	13
3.5 SineKAN Q 网络.....	13
3.6 集成算法流程.....	14
3.8 与参考论文结构的对应关系.....	15
3.7 能量管理建模的工程解释.....	15
4 结果与分析.....	15

4.1 实验设计	15
4.2 LSTM 预测结果占位	15
4.3 固定权重 LSTM-MPC 结果占位.....	16
4.4 SineKAN-DQN 动态调权结果占位	16
4.5 结果讨论模板.....	17
4.7 参数敏感性与可解释性分析模板.....	17
4.6 图表生成路径与脚本核验清单.....	18
5 结论、不足与展望.....	18
5.1 结论.....	18
5.2 不足.....	18
5.3 展望.....	18
5.4 假设与未指定项.....	18
参考文献.....	19

(自动目录：在 Word 中打开后，选择“引用/目录”或右键“更新域”即可刷新页码与标题。)

1 引言

1.1 研究背景

航运业低碳化与船舶动力系统电气化的发展使燃料电池/锂电池混合动力系统逐渐成为内河船舶、港作船、交通船和固定航线客船的重要技术路线。燃料电池以氢气为能量载体，通过电化学反应将化学能直接转化为电能，具有船端局部零碳排放、噪声低和效率较高等优势。锂电池具有快速功率响应能力，能够承担负荷尖峰、加速工况和预测误差补偿。二者协同可同时利用燃料电池的持续供能能力和电池的快速动态能力，是氢能船舶能量管理研究的典型对象。

与陆用车辆相比，船舶负荷具有更强的阶段性和持续性。船舶在离港、加速、巡航、靠泊、低速运行和待机等阶段表现出不同负荷形态，且推进负荷、日用负荷、辅助设备负荷、冷却泵、通风系统、氢安全系统和电力电子设备损耗相互耦合。这使船端用电需求并不等同于单一推进逆变器有功功率。若仅以推进逆变器功率作为总负荷，会造成模型功率平衡口径与能源侧设备功率不一致。

燃料电池适合承担平滑的中低频主功率，但其动态响应过程涉及供氢、供氧、水热管理、电堆湿度和辅助系统协同，频繁大幅功率变化可能影响效率、可靠性与寿命。锂电池适合承担高频波动与短时差额，但 SOC 必须保持在安全区间内，且高频充放电会增加电池吞吐和潜在寿命损耗。因此，混合动力船舶能量管理的核心不是简单地使某一电源完全跟随负荷，而是在氢耗、燃料电池平滑性、电池吞吐和 SOC 安全之间形成动态权衡。

1.2 研究问题

本文关注的问题可概括为：在真实航段负荷存在强波动、多阶段和预测误差的条件下，如何构建一种既能利用未来负荷信息、又能显式处理物理约束、同时具备多工况权重自适应能力的燃料电池/锂电池混合动力船舶能量管理方法。为此，本文采用“LSTM 负荷预测—MPC 滚动优化—SineKAN-DQN 动态调权”的分层结构。

该结构中，LSTM 负责利用历史负荷序列预测下一控制时域的短时负荷趋势；MPC 负责在燃料电池、电池和 SOC 约束下求解燃料电池功率轨迹；DQN 不直接输出功率控制量，而是在离散权重动作空间中选择 MPC 目标函数权重。这样设计的关键原因是：若由强化学习直接输出功率，需要其同时学习功率平衡、设备约束与安全边界，训练外工况风险较高；而由 DQN 调节 MPC 权重，可以使物理约束仍由 MPC 承担，使强化学习仅负责工况偏好的高层选择。

1.3 国内外研究现状

1.3.1 混合动力船舶能量管理研究

从船舶应用角度看，燃料电池系统与电池储能系统并不是简单并联电源。燃料电池的高效率区间通常对应相对稳定的输出功率，过度频繁的输出变化会使空气供应、氢气供应、热管理和水管理系统处于频繁调节状态，从而影响系统效率和寿命。锂电池虽然具备较快的动态响应能力，但其 SOC、充

放电倍率、温度和循环寿命约束决定了它不宜长期承担平均负荷。因此，混合动力船舶能量管理的理论基础是频率分工和能量平衡：燃料电池承担中低频主功率，锂电池承担高频波动与短时差额。

现有船舶混合动力能量管理研究中，滤波型方法常将负荷分解为低频和高频分量，再分别分配给燃料电池和电池。该类方法直观但依赖滤波参数，且难以显式处理 SOC 约束。基于优化的方法能够将氢耗、电池寿命、SOC、安全约束和功率平衡纳入统一目标函数。MPC 进一步利用未来负荷预测和滚动反馈机制，使其特别适合船舶这种负荷变化相对慢但持续时间长的对象。

本文在此基础上不采用纯规则法作为主策略，而是将其作为可选安全回退；主控制器采用可显式建模约束的 MPC，并进一步引入动态权重调节，使控制器在不同航段和不同 SOC 条件下调整目标偏好。

燃料电池/锂电池混合动力系统能量管理方法通常可分为规则型、优化型和学习型三类。规则型方法结构简单，常利用 SOC 阈值、功率阈值、等效低通滤波或经验分配规则实现燃料电池与储能之间的功率分配，适合作为工程初始策略或安全回退策略。然而规则参数依赖人工经验，难以应对航段负荷、SOC 状态和预测误差的联合变化。

优化型方法包括等效氢耗最小策略、动态规划、多目标优化和模型预测控制等。MPC 由于能够显式处理约束和预测时域，在船舶综合电力系统、混合推进和储能调度中具有较高适用性。其基本思想是在每个控制周期内基于当前状态与未来负荷预测求解有限时域优化问题，仅执行第一个控制量并滚动更新。对于燃料电池/电池船舶，MPC 能够同时考虑氢耗、SOC 偏差、电池吞吐、燃料电池功率波动和功率边界。

学习型方法近年来受到关注，尤其是 DQN、DDPG、PPO 等深度强化学习算法被用于混合动力车辆、船舶和微电网能量管理。强化学习具有根据环境反馈学习策略的能力，但直接输出功率控制量时，其安全性、可解释性和约束满足仍是工程应用难点。因此，将强化学习用于高层策略选择、参数调度或权重调整，而将底层功率分配交给可解释优化器，是更适合高安全场景的分层结构。

1.3.2 负荷预测与预测型能量管理

船舶负荷预测与一般建筑负荷预测存在差异。建筑负荷通常具有较强的日周期和气象相关性，而船舶负荷更多受到航速指令、操纵状态、设备启停、靠离泊阶段和水域环境的影响。当前项目中仅使用负荷历史序列进行 LSTM 预测，因此模型能够捕捉负荷惯性和局部趋势，但对突发操纵或设备切换引起的阶跃变化难以完全提前识别。这也是后续引入预测不确定性和动态调权的原因之一。

在 LSTM-MPC 框架中，预测结果直接影响燃料电池功率规划。如果预测低估负荷，实际执行时锂电池需要承担更多差额；如果预测高估负荷，燃料电池可能提前升功率，随后在真实负荷较低时导致电池被动充电。因此，负荷预测不仅要看全局误差，也要看偏差方向、突变区域误差和高负荷低估率。

短时负荷预测是预测型能量管理的基础。LSTM 通过门控记忆机制缓解传统循环神经网络的梯度消失问题，适合处理船舶负荷这种具有历史相关性和阶段转换特征的时间序列。对于 LSTM-MPC，负荷预测的目标不是无限期精确外推，而是在有限预测时域内提供趋势信息，使 MPC 能提前安排燃料电池功率并降低电池过度补偿。

在滚动控制中，近端预测通常比远端预测对当前控制更重要。以 30 s 采样周期和 6 步预测为例，h1 至 h3 对下一两分钟内的可执行控制影响更直接，h4 至 h6 主要影响燃料电池平滑趋势和 SOC 预判。因此，模型训练与评估不应只追求远端 h6 最优，而应综合近端预测误差、突变区误差和高负荷低估风险。

1.3.3 DQN、KAN 与 SineKAN 研究进展

DQN 在本文中的作用不同于传统端到端控制器。传统端到端强化学习通常直接输出控制量，例如燃料电池功率或电池功率参考值，这要求智能体在训练过程中同时学习复杂的物理约束、功率边界和安全策略。本文将动作定义为 MPC 权重组，使 DQN 成为“目标偏好调度器”。这种定义缩小了动作空间，也使每个动作都具备明确物理意义。

SineKAN 作为 Q 网络的意义在于改善状态—动作价值函数近似。船舶能量管理状态包含 SOC、负荷水平、负荷变化率、预测均值、预测方差和上一时刻动作等变量，这些变量与最优权重之间的关系并不线性。相比 MLP 的固定节点激活，KAN 类网络通过边函数表示非线性关系；相比 B 样条 KAN，SineKAN 的正弦基函数可能更适合描述多频率波动特征。本文将其作为待验证的结构假设，并在实验设计中安排与 MLP-DQN、KAN-DQN 的对照。

DQN 通过深度神经网络近似动作价值函数，将 Q-learning 扩展到高维状态空间。经验回放和目标网络提升了训练稳定性，Double DQN 减轻了最大化操作带来的过估计问题。对于本文任务，DQN 的动作可设计为有限个 MPC 权重组，使其成为多目标权重选择器而非直接功率控制器。

KAN 将传统 MLP 中节点上的固定激活函数转化为边上的可学习一元函数，提高了函数表达灵活性和一定可解释性。SineKAN 进一步以正弦基函数构造边函数。船舶负荷虽非严格周期信号，但其航段阶段、设备启停和功率波动具有明显多频率特征，因此 SineKAN 可作为 DQN Q 网络的候选结构，与 MLP-DQN 和普通 KAN-DQN 进行对比。需要强调的是，SineKAN 的优势属于待实验验证命题，不能在结果未完成前写成既成结论。

1.4 本文研究内容与章节安排

参照燃料电池混合动力能量管理类论文常见组织方式，本文将结构调整为五章：第 1 章为引言，阐述背景、问题、研究现状和本文贡献；第 2 章为混合动力船舶数学建模，围绕“三峡氢舟 1 号”、能源侧等效负荷、燃料电池、锂电池、氢耗曲线和约束建立模型；第 3 章为算法与能量管理建模，系统介绍 LSTM、MPC、DQN、SineKAN 及其集成流程；第 4 章为结果与分析，给出实验设计、图表占位和分析模板；第 5 章为结论、不足与展望。

2 混合动力船舶数学建模

2.1 研究对象与动力系统组成

本文研究对象为“三峡氢舟 1 号”燃料电池/锂电池混合动力船舶。该船动力系统由燃料电池系统、锂电池系统、直流配电板、推进电机、交流配电板、自动化系统和 EMS 等组成。燃料电池系统由左右共 8 个燃料电池模块构成，总额定功率为 560 kW；锂电池系统总储能为 1806 kWh；推进系统采用双舵桨推进，额定推进功率为 2×500 kW；日用负荷等级为 100 kVA。经济航速下燃料电池作为主供电源，锂电池作为辅助电源；高速或高功率需求阶段，燃料电池与锂电池共同供电。

表 2-1 “三峡氢舟 1 号”关键技术参数

参数类别	数值	说明
燃料电池总功率	560 kW	左右共 8 个燃料电池模块求和
锂电池总储能	1806 kWh	全船等效负荷口径下的储能容量基线
额定推进功率	2×500 kW	双舵桨推进
日用负荷	100 kVA	辅助与日用系统负荷等级
采样周期	30 s	LSTM 与 MPC 当前实现的时间步长
航段数量	66 段	按航段起始时间顺序划分
训练/验证/测试	46/13/7 段	时间顺序 7:2:1 划分

2.2 能源侧等效总负荷建模

初始数据处理中，左右推进逆变器有功功率之和只能反映推进侧负荷，不能完全代表全船用能需求。船舶实际还存在日用负荷、冷却系统、通风设备、直流母线支路、逆变器损耗、控制系统和氢安全系统等负荷。因此，本文采用能源侧反推的等效总负荷：

$$P_{\text{load}}(t) = P_{\text{fc,total}}(t) + P_{\text{bat,total}}(t) \quad (2-1)$$

式中， $P_{\text{load}}(t)$ 为用于 LSTM 训练与 MPC 控制的能源侧等效总负荷， $P_{\text{fc,total}}(t)$ 为燃料电池总发电功率， $P_{\text{bat,total}}(t)$ 为锂电池带符号净功率。

$$P_{\text{fc,total}}(t) = \sum_{i=1}^8 P_{\text{fc},i}(t) \quad (2-2)$$

$$P_{\text{bat,total}}(t) = \sum_{j=1}^{N_b} \left[-\frac{U_{\text{BDM},j}(t)I_{\text{BDM},j}(t)}{1000} \right] \quad (2-3)$$

其中电池功率约定放电为正、充电为负。该定义是能源侧等效负荷，不等同于独立总负荷传感器的直接测量值，其精度仍受数据同步、传感器口径和变换损耗影响。

2.3 航段数据集与预处理模型

本文采用 66 个实船航段构建数据集，并按航段起始时间顺序划分为训练集 46 段、验证集 13 段和测试集 7 段。采用时间顺序划分的原因在于真实部署时模型只能利用前期航段训练，再对后期未知航段进行预测和控制。若将同一航段内相邻窗口随机拆分到训练和测试集合，容易导致数据泄漏并使测试结果虚高。

数据预处理包括时间戳排序、采样间隔校验、缺失值标记与插值、异常值检查、航段边界保护、负荷非负物理投影和归一化处理。归一化器仅使用训练集拟合，验证集和测试集使用相同归一化参数。LSTM 滑动窗口不得跨航段，以避免把上一航段结尾与下一航段开头错误连接。

表 2-2 数据预处理与建模输入构建流程

步骤	处理内容	说明
1	读取 66 个航段 Excel	核验字段、时间戳和采样间隔
2	构造 load_total_kw	采用燃料电池总功率 + 电池带符号净功率
3	航段级划分	Train/Val/Test = 46/13/7
4	归一化	仅使用训练集拟合归一化器
5	滑动窗口构造	history_len=18, pred_horizon=6, 窗口不跨航段
6	输出结果	用于 LSTM 训练、MPC 测试和后续 DQN 环境

2.4 直流母线功率平衡模型

忽略变换器损耗并将辅助支路等效吸收到负荷侧时，直流母线功率平衡可表示为：

$$P_{\text{load}}(k) = P_{\text{fc}}(k) + P_{\text{bat}}(k) + P_{\text{unserved}}(k) - P_{\text{curtailed}}(k) \quad (2-4)$$

式中 $P_{\text{unserved}}(k)$ 表示未满足负荷， $P_{\text{curtailed}}(k)$ 表示过剩功率或弃能项。理想可行控制下二者应尽量为零。

若考虑 DC/DC 和逆变器效率，可写为扩展形式：

$$P_{\text{load}}(k) = \eta_{\text{fc}} P_{\text{fc}}(k) + \eta_{\text{dis}} P_{\text{bat}}^{\text{dis}}(k) - \frac{P_{\text{bat}}^{\text{ch}}(k)}{\eta_{\text{ch}}} \quad (2-5)$$

当前阶段由于变换器效率和设备侧口径尚需进一步核验，本文先采用等效功率平衡形式，并在结果分析中保留效率参数待补充说明。

2.5 燃料电池功率、效率与氢耗模型

燃料电池输出功率由电堆电压与电流决定：

$$P_{\text{fc}}(k) = V_{\text{fc}}(k) I_{\text{fc}}(k) \quad (2-6)$$

基于法拉第定律，氢气消耗率可表示为：

$$m_{H_2}(k) = \frac{N_{\text{cell}} M_{H_2} I_{\text{fc}}(k)}{2F\eta_F} \quad (2-7)$$

其中 N_{cell} 为电堆单体数， M_{H_2} 为氢气摩尔质量， F 为法拉第常数， η_F 为法拉第效率。若实际项目使用厂家或台架功率-氢耗曲线，则应以曲线标定结果为准。

功率-氢耗曲线可写为：

$$m_{H_2,k} = f_{H_2}(P_{\text{fc},k})\Delta t \quad (2-8)$$

$$f_{H_2}(P_{\text{fc}}) = aP_{\text{fc}}^2 + bP_{\text{fc}} + c \quad (2-9)$$

其中 a 、 b 、 c 应由实测数据或技术文件标定，本文不自行编造。

$$\eta_{\text{fc}}(k) = \frac{P_{\text{fc}}(k)}{m_{H_2}(k) \cdot LHV_{H_2}} \quad (2-10)$$

燃料电池功率边界为：

$$0 \leq P_{\text{fc}}(k) \leq P_{\text{fc}}^{\max} \quad (2-11)$$

本文不将文献中 1 s 采样条件下的 48 kW/step 硬爬坡约束直接套用于 30 s 控制周期。若直接套用，会人为压低燃料电池在当前仿真步长下的动态能力。本文采用目标函数中的软惩罚描述燃料电池平滑性：

$$J_{\text{ramp}} = \sum_{k=0}^{N-1} q_{\text{ramp}} (P_{\text{fc},k} - P_{\text{fc},k-1})^2 \quad (2-12)$$

2.6 锂电池 SOC 与吞吐模型

锂电池净功率 $P_{\text{bat}}(k)$ 约定放电为正、充电为负。SOC 动态可写为：

$$SOC(k+1) = SOC(k) - \frac{P_{\text{bat}}(k)\Delta t}{E_{\text{bat}}} \quad (2-13)$$

对于当前能源侧等效总负荷口径， E_{bat} 采用全船储能容量基线 1806 kWh。

若进一步考虑充放电效率，则可扩展为：

$$SOC(k+1) = SOC(k) - \frac{P_{\text{bat}}^{\text{dis}}(k)\Delta t}{\eta_{\text{dis}}E_{\text{bat}}} + \frac{\eta_{\text{ch}}P_{\text{bat}}^{\text{ch}}(k)\Delta t}{E_{\text{bat}}} \quad (2-14)$$

$$-P_{\text{bat}}^{\text{ch},\max} \leq P_{\text{bat}}(k) \leq P_{\text{bat}}^{\text{dis},\max} \quad (2-15)$$

$$SOC^{\min} \leq SOC(k) \leq SOC^{\max} \quad (2-16)$$

电池吞吐能量用于表征电池使用强度，不抵消充放电能量：

$$E_{\text{bat}}^{\text{thr}} = \sum_k |P_{\text{bat}}(k)| \Delta t \quad (2-17)$$

若采用充放电拆分变量，也可写为：

$$E_{\text{bat}}^{\text{thr}} = \sum_k [P_{\text{bat}}^{\text{dis}}(k) + P_{\text{bat}}^{\text{ch}}(k)] \Delta t \quad (2-18)$$

参数：燃料电池氢耗曲线系数 a 、 b 、 c ；状态：待实船/台架数据标定。参数：电池充放电效率；状态：待设备参数核验。参数：变换器效率；状态：可在扩展模型中补充。参数：MPC 求解器与容差；状态：以代码仓库实际配置为准。

表 2-3 模型参数来源与待补充项（占位）

燃料电池氢耗曲线是后续氢耗指标可信性的关键。若项目代码已经使用 **Dp0** 或其他实测曲线，应在最终论文中给出曲线来源、插值方法、拟合形式与拟合误差；若只采用经验系数，则应说明其适用范围和不确定性。电池模型方面，本文当前采用等效容量和能量守恒更新 **SOC**，能够满足能量管理层仿真需求；若进一步研究寿命衰减，则需引入等效循环次数、温度、倍率和 **SOC** 区间相关的退化模型。

本文建模采用“先建立可解释控制框架，再由实船数据补充参数”的思路。当前已经明确的工程参数包括燃料电池总功率、锂电池总容量、推进功率、日用负荷等级、采样周期和航段划分；尚需后续核验的参数包括燃料电池氢耗曲线拟合系数、电池充放电效率、DC/DC 变换器效率、电池最大充放电功率边界以及实际 EMS 中的安全限值。

2.7 建模假设与参数标定需求

3 算法与能量管理建模

3.1 总体框架

本文算法框架由三层构成：第一层为 **LSTM** 短时多步负荷预测层，输出下一控制时域 $t+1$ 至 $t+6$ 的负荷预测；第二层为 **MPC** 滚动优化层，根据预测负荷、**SOC** 和上一时刻燃料电池功率求解下一时域燃料电池功率轨迹；第三层为 **SineKAN-DQN** 动态权重调节层，根据 **SOC**、预测负荷、不确定性和功率状态选择 **MPC** 目标函数权重。

图 3-1 LSTM-SineKAN-DQN-MPC 总体框架图（占位，待插入流程图）

图 3-1 应包括：实船航段数据、能源侧等效负荷、**LSTM** 预测器、MC Dropout 不确定性估计、**SineKAN-DQN** 权重选择器、**MPC** 优化器、燃料电池执行功率、锂电池差额补偿、**SOC** 更新和性能指标反馈。

3.2 LSTM 负荷预测模型

LSTM 的核心是通过门控机制保留或遗忘历史信息。给定输入 x_t 、上一时刻隐藏状态 h_{t-1} 和记忆状态 c_{t-1} ，**LSTM** 计算过程为：

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (3-1)$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (3-2)$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c) \quad (3-3)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (3-4)$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (3-5)$$

$$h_t = o_t \odot \tanh(c_t) \quad (3-6)$$

其中遗忘门 f_t 控制历史记忆保留程度，输入门 i_t 控制当前信息写入程度，输出门 o_t 控制单元状态暴露到隐藏状态的程度。本文输入序列为历史 H 个负荷采样点：

$$X_t = [P_{\text{load}}(t - H + 1), P_{\text{load}}(t - H + 2), \dots, P_{\text{load}}(t)] \quad (3-7)$$

输出为未来 6 个采样点负荷：

$$\hat{Y}_t = [\hat{P}_{\text{load}}(t + 1), \hat{P}_{\text{load}}(t + 2), \dots, \hat{P}_{\text{load}}(t + 6)] \quad (3-8)$$

训练损失可采用 Huber 或加权 Huber 损失。Huber 损失为：

$$L_\delta(e) = \begin{cases} \frac{1}{2}e^2, & |e| \leq \delta \\ \delta\left(|e| - \frac{1}{2}\delta\right), & |e| > \delta \end{cases} \quad (3-9)$$

$$L = \frac{1}{B} \sum_{t=1}^B \sum_{k=1}^6 \alpha_k w_{t,k} L_\delta(\hat{P}_{\text{load}}(t + k) - P_{\text{load}}(t + k)) \quad (3-10)$$

其中 α_k 为预测步权重， $w_{t,k}$ 可用于高负荷、突变区或低估样本的非对称加权。由于 LSTM-MPC 每 30 s 重新滚动预测，h1 至 h3 对控制更关键，远端 h4 至 h6 主要影响燃料电池平滑趋势和 SOC 预判。

预测不确定性可通过 MC Dropout 估计。对同一输入进行 M 次随机前向传播：

$$\mu_k = \frac{1}{M} \sum_{m=1}^M \hat{P}_{\text{load},k}^{(m)} \quad (3-11)$$

$$\sigma_k^2 = \frac{1}{M-1} \sum_{m=1}^M (\hat{P}_{\text{load},k}^{(m)} - \mu_k)^2 \quad (3-12)$$

$$U_t = \frac{1}{6} \sum_{k=1}^6 \frac{\sigma_k}{|\mu_k| + \varepsilon} \quad (3-13)$$

该不确定性可作为 DQN 的状态输入。当预测不确定性较高时，动态调权器理论上可选择更保守的 MPC 权重。

3.3 MPC 滚动优化与能量管理模型

本文采用“下一控制时域”型 LSTM-MPC。时刻 t，系统执行上一轮缓存的燃料电池指令 $P_{\text{fc}}^{\text{cmd}}(t)$ ，当前实际负荷 $P_{\text{load}}(t)$ 已知，实际电池功率由差额得到：

$$P_{\text{bat}}(t) = P_{\text{load}}(t) - P_{\text{fc}}^{\text{cmd}}(t) \quad (3-14)$$

随后 LSTM 预测 t+1 至 t+6 的负荷，MPC 基于该预测序列求解下一控制时域燃料电池功率轨迹，并只缓存第一个控制量供 t+1 执行：

$$[\hat{P}_{\text{load}}(t + 1), \dots, \hat{P}_{\text{load}}(t + 6)] = \text{LSTM}(X_t) \quad (3-15)$$

$$P_{\text{fc}}^{\text{cmd}}(t + 1) = \text{first}\{\text{MPC}(\hat{P}_{\text{load}}(t + 1:t + 6), \text{SOC}(t + 1), P_{\text{fc}}^{\text{cmd}}(t))\} \quad (3-16)$$

当航段初始阶段 LSTM 历史不足时，采用当前负荷保持预测：

$$\hat{P}_{\text{load}}(t + 1) = \hat{P}_{\text{load}}(t + 2) = \dots = \hat{P}_{\text{load}}(t + 6) = P_{\text{load}}(t) \quad (3-17)$$

该方法不使用未来真实负荷，且每个控制周期都会重新读取当前负荷并构造新的临时预测序列。

MPC 预测时域 $N = 6$ ，采样周期 $\Delta t = 30$ s。目标函数采用 raw physical objective：

$$J = \sum_{k=0}^{N-1} [q_{h2} m_{H_2,k} + q_{\text{soc}} (\text{SOC}_{k+1} - \text{SOC}_{\text{ref}})^2 + q_{\text{bat}} E_{\text{bat},k}^{\text{thr}} + q_{\text{ramp}} (P_{\text{fc},k} - P_{\text{fc},k-1})^2] \quad (3-18)$$

预测窗口内计划电池功率为：

$$P_{\text{bat},k} = \hat{P}_{\text{load},k} - P_{\text{fc},k} \quad (3-19)$$

约束条件为:

$$0 \leq P_{fc,k} \leq P_{fc}^{max} \quad (3-20)$$

$$-P_{bat}^{ch,max} \leq P_{bat,k} \leq P_{bat}^{dis,max} \quad (3-21)$$

$$SOC^{min} \leq SOC_k \leq SOC^{max} \quad (3-22)$$

固定权重 MPC 的优势是物理意义清晰、约束处理明确、便于形成基线；局限是权重人工整定，且同一权重组难以同时适应高负荷、低负荷、SOC 紧张和高预测不确定性等状态。

图 3-2 LSTM-MPC 在线执行时序图（占位，待插入流程图）

3.4 DQN 动态权重调节模型

本文将 DQN 建模为 MPC 权重选择器。状态向量可包含 SOC、当前负荷、负荷变化率、LSTM 预测均值、预测方差、预测不确定性、上一时刻燃料电池功率、上一时刻电池功率和上一动作：

$$s_t = [SOC_t, P_{load}(t), \Delta P_{load}(t), \mu_{1:6}, \sigma_{1:6}, U_t, P_{fc}(t-1), P_{bat}(t-1), a_{t-1}] \quad (3-23)$$

动作空间为有限个 MPC 权重组：

$$a_t \in \{1, 2, \dots, K\}, a_t \mapsto (q_{h2}^{(a)}, q_{soc}^{(a)}, q_{bat}^{(a)}, q_{ramp}^{(a)}) \quad (3-24)$$

奖励函数设计为负运行代价，可包含氢耗、SOC 偏差、电池吞吐、燃料电池波动、安全越界和未满足负荷惩罚：

$$r_t = -[\lambda_{h2} m_{H2,t} + \lambda_{soc} (SOC_t - SOC_{ref})^2 + \lambda_{bat} |P_{bat,t}| \Delta t + \lambda_{ramp} (P_{fc,t} - P_{fc,t-1})^2 + \lambda_{safe} \Phi_{safe} + \lambda_{un} P_{unserved,t}] \quad (3-25)$$

$$\Phi_{safe} = \max(SOC^{min} - SOC_t, 0)^2 + \max(SOC_t - SOC^{max}, 0)^2 \quad (3-26)$$

最优 Q 函数满足 Bellman 最优方程：

$$Q^*(s_t, a_t) = \mathbb{E}[r_t + \gamma \max_{a'} Q^*(s_{t+1}, a') | s_t, a_t] \quad (3-27)$$

DQN 目标值和损失函数为：

$$y_t = r_t + \gamma \max_{a'} Q_{\theta^-}(s_{t+1}, a') \quad (3-28)$$

$$L_{DQN}(\theta) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} [(y_t - Q_{\theta}(s_t, a_t))^2] \quad (3-29)$$

若采用 Double DQN，则目标值可写为：

$$y_t^{DDQN} = r_t + \gamma Q_{\theta^-}(s_{t+1}, \arg \max_{a'} Q_{\theta}(s_{t+1}, a')) \quad (3-30)$$

3.5 SineKAN Q 网络

KAN 的核心思想是将传统 MLP 中节点上的固定激活函数转换为边上的可学习一元函数。KAN 层可表示为：

$$z_j^{l+1} = \sum_i \phi_{j,i}^l(z_i^l) \quad (3-31)$$

普通 KAN 常用 B 样条函数构造边函数：

$$\phi_{j,i}(x) = \sum_{m=1}^M c_{j,i,m} B_m(x) \quad (3-32)$$

SineKAN 将边函数改写为正弦基函数组合：

$$\phi_{j,i}(x) = \sum_{m=1}^M a_{j,i,m} \sin(\omega_m x + \varphi_{j,i,m}) + b_{j,i} \quad (3-33)$$

因此，SineKAN-DQN 的 Q 函数可写为：

$$Q_{\theta}(s, a) = \text{SineKAN}_{\theta}(s)_a \quad (3-34)$$

相对于 MLP-DQN，SineKAN-DQN 有望提高复杂非线性状态-动作价值函数的表达能力；相对于普通 KAN-DQN，SineKAN 的正弦基函数可能更适合具有多频率波动、阶段转换和局部振荡特征的船舶负荷状态。但这种优势需要通过统一状态、动作空间和奖励函数下的消融实验验证，不能在未完成实验前作确定性结论。

图 3-3 SineKAN-DQN 动态调权闭环图（占位，待插入流程图）

3.6 集成算法流程

算法 1 固定权重 LSTM-MPC 在线滚动优化流程：

输入：航段负荷序列、初始 SOC、上一时刻燃料电池功率、LSTM 模型、MPC 参数；

1. 读取当前实际负荷 $P_{\text{load}}(t)$ ，执行上一轮缓存的 $P_{\text{fc}}^{\text{cmd}}(t)$ ；
2. 计算 $P_{\text{bat}}(t) = P_{\text{load}}(t) - P_{\text{fc}}^{\text{cmd}}(t)$ ，并用实际 $P_{\text{bat}}(t)$ 更新 SOC；
3. 若 LSTM 历史窗口充足，则预测 $t+1$ 至 $t+6$ 负荷；否则采用 current-hold 预测；
4. 调用 MPC 求解下一控制时域燃料电池功率序列；
5. 缓存第一个控制量 $P_{\text{fc}}^{\text{cmd}}(t+1)$ ，进入下一采样周期。

算法 2 SineKAN-DQN 动态调权 MPC 流程：

输入：状态 s_t 、SineKAN Q 网络、经验回放池、LSTM 预测器和 MPC 模型；

1. 根据 SOC、负荷、预测均值、预测不确定性和上一动作构造状态 s_t ；
2. 按 ϵ -greedy 策略选择权重动作 a_t ；
3. 将动作映射为 $(q_{\text{h2}}, q_{\text{soc}}, q_{\text{bat}}, q_{\text{ramp}})$ ；
4. 在该权重组下运行 MPC 并执行当前控制时序；
5. 根据氢耗、SOC 偏差、电池吞吐、燃料电池波动和安全惩罚计算奖励 r_t ；
6. 存储 (s_t, a_t, r_t, s_{t+1}) 并从经验回放池采样更新 SineKAN-DQN；
7. 周期性同步目标网络，直至训练完成。

图 3-4 训练与测试流程图（占位，待插入流程图）

该调整使论文结构更接近燃料电池混合动力能量管理领域常见写法，也便于后续将结果图直接补入第 4 章。图表编号已按章重排，如系统参数表为表 2-1，算法框架图为图 3-1，结果图从图 4-1 开始。

用户提供的 ScienceDirect 论文结构可概括为：引言、船舶数学建模、算法与能量管理建模、结果与分析、结论。本文按同样逻辑调整章节：第 1 章集中讨论背景与研究问题；第 2 章将三峡氢舟 1 号、能源侧负荷、燃料电池、锂电池、氢耗曲线和功率约束统一到数学建模；第 3 章集中介绍 LSTM、MPC、DQN 与 SineKAN 的算法机理和能量管理集成；第 4 章仅保留真实结果图和表格的占位与分析模板；第 5 章给出结论、不足与未来工作。

3.8 与参考论文结构的对应关系

这种分工可以避免两个常见问题。第一，若直接让燃料电池跟随负荷，燃料电池功率会包含大量高频波动，不符合其作为主能源的运行特性；第二，若简单让电池承担所有动态波动而不考虑 SOC，则可能产生长时间净放电并降低安全裕度。MPC 通过约束和目标函数处理底层分配，DQN 则通过权重动作调整控制偏好，使策略更适应航段差异。

本文的能量管理建模可理解为三类变量的协同：负荷预测变量、优化控制变量和权重调度变量。负荷预测变量由 LSTM 输出，反映未来 3 min 内等效总负荷的趋势；优化控制变量由 MPC 求解，主要是未来时域内燃料电池功率序列；权重调度变量由 SineKAN-DQN 选择，决定氢耗、SOC、电池吞吐和燃料电池平滑性在当前状态下的相对重要程度。

3.7 能量管理建模的工程解释

4 结果与分析

4.1 实验设计

本章按照用户当前项目进度设置为结果占位与分析模板，不写任何尚未由代码产生的数值性结果。实验平台硬件环境、操作系统、Python 版本、深度学习框架版本、MPC 求解器版本和随机种子应在最终稿中列明；当前可标注为“待补充”。数据集采用 66 个航段，按时间顺序划分为 46/13/7，采样周期为 30 s。

表 4-1 对照组与消融实验设计

编号	方法	说明
C0	current-hold MPC	无 LSTM，仅当前负荷保持预测
C1	固定权重 LSTM-MPC	当前基线，DQN 不参与
C2	MLP-DQN-MPC	DQN Q 网络采用 MLP
C3	KAN-DQN-MPC	DQN Q 网络采用普通 KAN
C4	SineKAN-DQN-MPC	本文拟采用的动态调权方法
C5	消融：无不确定性输入	去除 MC Dropout 不确定性状态
C6	消融：不同动作空间规模	比较权重组数量影响

4.2 LSTM 预测结果占位

图 4-1 测试集航段 LSTM h1 预测与真实负荷对比（占位）

此处待插入 prediction_examples.png。建议数据来源为 outputs/lstm_total_load_721/prediction_examples.png 或后续最佳模型对应目录。图中横轴为时间，纵轴

为负荷功率/kW，子图应展示测试集 7 个航段的真实负荷与 h1 预测曲线。分析时应关注趋势跟踪能力、突变滞后、低负荷阶段误差以及预测步长增加导致误差扩散的现象。

表 4-2 LSTM h1~h6 预测误差统计（占位）

此处待由 metrics.csv 与 forecast_horizon_metrics.csv 填充。建议列包括 RMSE、MAE、WAPE、Bias、under_prediction_rate、high_load_MAE、ramp_region_MAE。由于 LSTM-MPC 每个控制周期重新滚动，h1~h3 对当前控制更关键，应单独分析近端预测表现。

4.3 固定权重 LSTM-MPC 结果占位

图 4-2 固定权重 LSTM-MPC 功率分配与 SOC 曲线（占位）

此处待插入 fixed_mpc_p6_comparison.png。建议路径为 outputs/lstm_mpc_total_load_test/fixed_mpc_p6_comparison.png。图中应包含 Load、 P_{fc} 、 P_{batt} 与 SOC。分析应说明燃料电池是否承担主功率、锂电池是否承担动态差额、SOC 是否保持在安全区间，以及 $P_{batt} = Load - P_{fc}$ 导致的功率互补现象。

图 4-3 SOC 演化曲线与安全区间（占位）

此处待由 fixed_mpc_p6_timeseries.csv 生成。图中应标注 SOC_start、SOC_end、SOC_min、SOC_max、 SOC_{ref} 和 SOC_reserve。若 SOC 低于安全线，应分析是权重设置、负荷预测误差、容量口径还是约束配置造成。

表 4-3 氢耗与电池吞吐指标（占位）

此处待由 fixed_mpc_p6_metrics.csv 填充。建议列包括 H2_total_kg、charge_sustaining_adjusted_H2、battery_discharge_kwh、battery_charge_kwh、battery_net_discharge_kwh、battery_throughput_kwh。

表 4-4 燃料电池功率跟踪与波动指标（占位）

建议指标包括 fc_ramp_mean_kw、fc_ramp_max_kw、fc_load_tracking_mae、fc_load_tracking_bias、fc_above_load_energy_kwh、fc_below_load_energy_kwh。若 fc_above_load_energy_kwh 较大，说明负荷下降后燃料电池仍高于负荷，导致电池被动充电；若 fc_below_load_energy_kwh 较大，说明负荷上升阶段电池承担较多差额。

4.4 SineKAN-DQN 动态调权结果占位

图 4-4 DQN 训练奖励曲线（占位）

此处待 RL 训练完成后补充，建议文件名为 dq_n_training_curve.png，脚本名待以仓库实际文件为准。分析应关注累计奖励是否收敛、训练是否存在震荡、SineKAN-DQN 与 MLP-DQN/KAN-DQN 收敛速度差异。

图 4-5 不同工况下的权重动作选择频次（占位）

此处待由 policy_action_frequency.csv 或对应绘图脚本生成。建议按 SOC 区间、负荷区间、预测不确定性区间统计动作选择频次，以验证 DQN 是否在高负荷或高不确定性状态下选择更保守权重。

表 4-5 消融实验结果对比（占位）

此处待由 `ablation_compare.csv` 填充。行应包括固定权重 LSTM-MPC、MLP-DQN-MPC、KAN-DQN-MPC、SineKAN-DQN-MPC、无不确定性输入等；列应包括氢耗、充电维持修正氢耗、SOC 偏差、电池吞吐、燃料电池平均功率变化、未满足负荷和求解成功率。

4.5 结果讨论模板

LSTM 多步预测误差通常会随预测步长增加而扩散。对于船舶负荷，负荷突变往往与操纵、设备启停或航段阶段切换有关，仅凭历史负荷序列难以完全提前识别。因此，结果分析时不应只比较 h_6 ，而应关注 $h_1 \sim h_3$ 在滚动控制中的实际影响。

固定权重 MPC 的性能取决于权重设置。若 q_{ramp} 偏大，燃料电池响应可能过慢，锂电池会承担过多中低频差额；若 q_{ramp} 偏小，燃料电池可能过度贴合负荷，削弱电池承担高频波动的作用。若 q_{soc} 过大，电池使用会被抑制；若 q_{soc} 过小，SOC 可能出现持续下降。DQN 动态调权的价值在于根据状态在这些偏好之间切换。

SineKAN-DQN 的优势需要通过对照实验验证。理论上，SineKAN 的边函数表达可以增强对阶段性、多频率状态的拟合能力，但如果动作空间设计不合理、奖励权重不稳定或训练样本不足，也可能无法优于 MLP-DQN。因此，最终论文结论应基于真实消融结果而非理论预设。

在动态调权阶段，应分析不同动作在不同状态区域的出现频次。若 SineKAN-DQN 在高不确定性、高负荷或低 SOC 区域更常选择保守权重，而在 SOC 充足、低负荷区域选择经济权重，则说明调权策略具备符合物理直觉的可解释性。若动作频繁抖动，则需要考虑动作切换惩罚、目标网络更新频率或奖励尺度归一化。

在固定权重 MPC 阶段，应重点分析 q_{ramp} 、 q_{soc} 和 q_{batt} 的影响。 q_{ramp} 增大通常使燃料电池更平滑，但可能导致负荷上升时电池承担更多中低频差额、负荷下降时燃料电池过发并使电池被动充电； q_{soc} 增大有利于保持 SOC，但可能抑制电池参与； q_{batt} 增大有利于降低电池吞吐，但可能使燃料电池更贴近负荷。

4.7 参数敏感性与可解释性分析模板

`prediction_examples.png` 对应图 4-1；`forecast_horizon_metrics.csv` 对应表 4-2；`fixed_mpc_p6_comparison.png` 对应图 4-2；`fixed_mpc_p6_timeseries.csv` 对应图 4-3；`fixed_mpc_p6_metrics.csv` 对应表 4-3；`dqn_training_curve.png` 对应图 4-4；`policy_action_frequency.csv/png` 对应图 4-5；`ablation_compare.csv` 对应表 4-5。具体脚本名以代码仓库核验结果为准。

表 4-6 后续图表文件与论文位置对应表（占位）

后续补图时，LSTM 预测结果图建议来自 `outputs/lstm_total_load_721/prediction_examples.png` 或最佳模型目录；LSTM 预测误差表建议由 `metrics.csv` 和 `forecast_horizon_metrics.csv` 生成；固定权重

LSTM-MPC 图建议来自 `outputs/lstm_mpc_tatal_load_test/fixed_mpc_p6_comparison.png`；SOC 细节曲线可由 `fixed_mpc_p6_timeseries.csv` 绘制；DQN 训练曲线、动作频次和消融对比图需在 RL 训练完成后补充。

4.6 图表生成路径与脚本核验清单

5 结论、不足与展望

5.1 结论

本文围绕燃料电池/锂电池混合动力船舶能量管理问题，构建了 LSTM 负荷预测、MPC 滚动优化和 SineKAN-DQN 动态权重调节相结合的分层框架。该框架以能源侧等效总负荷为建模对象，利用 LSTM 提供下一控制时域的多步负荷信息，以 MPC 在物理约束下求解燃料电池功率轨迹，并通过 SineKAN-DQN 根据 SOC、预测负荷和不确定性状态选择 MPC 目标函数权重。

从方法结构上看，本文没有将 DQN 设计为直接功率控制器，而是将其限制在高层权重调节角色。这种设计能够保留 MPC 在功率平衡、SOC 安全和设备约束处理方面的可解释性，同时引入强化学习对不同航段和不同负荷状态的自适应能力。当前论文完成了研究背景、系统建模、算法原理、实验设计与结果占位的整理，后续需补充最终流程图、预测图、LSTM-MPC 结果图、DQN 训练曲线和消融实验表格。

5.2 不足

当前研究仍存在若干不足。第一，虽然数据集由 66 个真实航段构成，并采用时间顺序划分，但测试集仅包含 7 个后期航段，统计稳健性仍需更多航段和跨季节数据验证。第二，能源侧等效总负荷由燃料电池功率与带符号电池功率反推得到，能够弥补推进负荷口径不足，但仍不是独立负荷传感器直接测得的真实总负荷，需进一步核验辅助负荷、变换器损耗和数据同步误差。第三，DQN 动态调权模块尚需完成训练与消融实验，SineKAN 相对 MLP 和普通 KAN 的优势不能在结果未完成前作确定结论。第四，MPC 求解实时性、控制通信延迟和安全回退策略仍需在硬件在环或实船系统中验证。

5.3 展望

后续研究应首先完成 LSTM 预测模型的重标定和测试集误差分析，固定一组可解释的 MPC 基准权重；随后分别训练 MLP-DQN、KAN-DQN 与 SineKAN-DQN 三类调权器，并在相同状态、动作空间和奖励函数下进行消融对比。进一步工作可引入燃料电池退化成本、电池寿命模型、不确定性约束 MPC、连续动作调权、航速与操纵指令特征、天气水文信息和硬件在环验证，以提高方法的工程可部署性。

5.4 假设与未指定项

表 5-1 假设与未指定项

项目	状态	处理方式
氢耗曲线参数 a、b、c	未知	需由实船/台架标定或代码配置补充
电池充放电效率	未知	需由设备参数或数据辨识确定
MPC 求解器名称与版本	待核验	以代码仓库实际依赖为准
Python 与深度学习框架版本	待补充	由实验环境记录
DQN 是否使用 Double DQN	待核验	以最终代码为准
DQN 经验池大小	待补充	训练脚本确定
SineKAN 层数与频率网格	待补充	训练配置确定
流程图脚本	待生成	可由 Mermaid 或 Visio 绘制
DQN 训练曲线	待生成	RL 训练完成后补充

参考文献

- [1] 中国船舶集团有限公司第七一二研究所. “三峡氢舟 1 号”动力系统系统技术规格书[R]. 2025.
- [2] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [3] Gers F A, Schmidhuber J, Cummins F. Learning to forget: Continual prediction with LSTM[J]. Neural Computation, 2000, 12(10): 2451-2471.
- [4] Gal Y, Ghahramani Z. Dropout as a Bayesian approximation: Representing model uncertainty in deep learning[C]//ICML. 2016: 1050-1059.
- [5] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518: 529-533.
- [6] Lin L J. Self-improving reactive agents based on reinforcement learning, planning and teaching[J]. Machine Learning, 1992, 8: 293-321.
- [7] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double Q-learning[C]//AAAI. 2016.
- [8] Schaul T, Quan J, Antonoglou I, Silver D. Prioritized experience replay[EB/OL]. arXiv:1511.05952, 2015.
- [9] Watkins C J C H, Dayan P. Q-learning[J]. Machine Learning, 1992, 8: 279-292.
- [10] Sutton R S, Barto A G. Reinforcement Learning: An Introduction[M]. 2nd ed. Cambridge: MIT Press, 2018.
- [11] Liu Z, Wang Y, Vaidya S, et al. KAN: Kolmogorov-Arnold Networks[EB/OL]. arXiv:2404.19756, 2024.
- [12] Reinhardt E A F, Dinesh P R, Gleyzer S. SineKAN: Kolmogorov-Arnold Networks Using Sinusoidal Activation Functions[J/OL]. Frontiers in Artificial Intelligence, 2025, 7. DOI: 10.3389/frai.2024.1462952.
- [13] Rawlings J B, Mayne D Q, Diehl M. Model Predictive Control: Theory, Computation, and Design[M]. 2nd ed. Nob Hill Publishing, 2017.
- [14] Borrelli F, Bemporad A, Morari M. Predictive Control for Linear and Hybrid Systems[M]. Cambridge: Cambridge University Press, 2017.

- [15] Geertsma R D, Negenborn R R, Visser K, Hopman J J. Design and control of hybrid power and propulsion systems for smart ships: A review of developments[J]. *Applied Energy*, 2017, 194: 30-54.
- [16] Bassam A M, Phillips A B, Turnock S R, Wilson P A. An improved energy management strategy for a hybrid fuel cell/battery passenger vessel[J]. *International Journal of Hydrogen Energy*, 2016, 41(47): 22453-22464.
- [17] Van Biert L, Godjevac M, Visser K, Aravind P V. A review of fuel cell systems for maritime applications[J]. *Journal of Power Sources*, 2016, 327: 345-364.
- [18] Antonopoulos S, Visser K, Kalikatzarakis M, et al. MPC framework for the energy management of hybrid ships with an energy storage system[J]. *Journal of Marine Science and Engineering*, 2021, 9(9): 993.
- [19] Kalikatzarakis M, Geertsma R D, Boonen E J, Visser K, Negenborn R R. Ship energy management for hybrid propulsion and power supply with shore charging[J]. *Control Engineering Practice*, 2018, 76: 133-154.
- [20] Jiang J, Zou L, Liu X, Pang S, Zhang L. An energy management method for combined load forecasting of fuel cell ships[J]. *Journal of Physics: Conference Series*, 2024, 2876(1): 012052.
- [21] Amphlett J C, Mann R F, Peppley B A, Roberge P R, Rodrigues A. A model predicting transient responses of proton exchange membrane fuel cells[J]. *Journal of Power Sources*, 1996, 61(1-2): 183-188.
- [22] Pukrushpan J T, Stefanopoulou A G, Peng H. Control of fuel cell breathing[J]. *IEEE Control Systems Magazine*, 2004, 24(2): 30-46.
- [23] Larminie J, Dicks A. *Fuel Cell Systems Explained*[M]. 2nd ed. Chichester: Wiley, 2003.
- [24] Doyle M, Fuller T F, Newman J. Modeling of galvanostatic charge and discharge of the lithium/polymer/insertion cell[J]. *Journal of the Electrochemical Society*, 1993, 140(6): 1526-1533.
- [25] Tremblay O, Dessaint L A. Experimental validation of a battery dynamic model for EV applications[J]. *World Electric Vehicle Journal*, 2009, 3(2): 289-298.
- [26] Bercibar M, Gandiaga I, Villarreal I, Omar N, Van Mierlo J, Van den Bossche P. Critical review of state of health estimation methods of Li-ion batteries for real applications[J]. *Renewable and Sustainable Energy Reviews*, 2016, 56: 572-587.
- [27] Zhang J, Lee J. A review on prognostics and health monitoring of Li-ion battery[J]. *Journal of Power Sources*, 2011, 196(15): 6007-6014.
- [28] Dedes E K, Hudson D A, Turnock S R. Assessing the potential of hybrid energy technology to reduce exhaust emissions from global shipping[J]. *Energy Policy*, 2012, 40: 204-218.
- [29] Zahedi B, Norum L E. Modeling and simulation of all-electric ships with low-voltage DC hybrid power systems[J]. *IEEE Transactions on Power Electronics*, 2013, 28(10): 4525-4537.
- [30] Khan M M S, Faruque M O, Newaz A. Fuzzy logic based energy storage management system for MVDC power system of all electric ship[J]. *IEEE Transactions on Energy Conversion*, 2017, 32(2): 798-809.
- [31] Yoo Y, Lee J, Han S, et al. Energy management strategy for hybrid electric ships based on equivalent consumption minimization strategy[J]. *Journal of Marine Science and Engineering*, 2020, 8(8): 624.

- [32] Fletcher T, Thring R, Watkinson M. An energy management strategy to concurrently optimise fuel consumption and PEM fuel cell lifetime in a hybrid vehicle[J]. International Journal of Hydrogen Energy, 2016, 41(46): 21503-21515.
- [33] Onori S, Serrao L, Rizzoni G. Hybrid Electric Vehicles: Energy Management Strategies[M]. London: Springer, 2016.
- [34] Kingma D P, Ba J. Adam: A method for stochastic optimization[EB/OL]. arXiv:1412.6980, 2014.
- [35] Srivastava N, Hinton G, Krizhevsky A, Sutskever I, Salakhutdinov R. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15: 1929-1958.
- [36] Huber P J. Robust estimation of a location parameter[J]. The Annals of Mathematical Statistics, 1964, 35(1): 73-101.